

Application du compressed sensing au cas de l'imagerie satellite

Kolia Iakovlev - Samuel Ritchie

Ensaie ParisTech

25/03/2018

Plan de la présentation

- 1 Introduction
- 2 Théorie du compressed sensing
- 3 Reconstruction de signaux satellites multidimensionnels
- 4 Mise en pratique et application à une image 2D

Pourquoi le compressed sensing?

- Traitement de signal audio ou d'imagerie
- Technique habituelle (fréquence de Nyquist-Shanon) trop coûteuse si l'image est trop lourde (cas particulier des images satellites)
- L'acquisition et la compression en une seule étape =
Technique du **compressed sensing**
- Gain en coût de stockage

Principe et notations

- 1 Supposons qu'un signal $x_0 \in \mathbb{R}^N$ soit trop 'grand' pour être stocké
- 2 On préfère alors récupérer un vecteur de mesures $y \in \mathbb{R}^M$, transformation linéaire de x_0 par une matrice $\Phi \in M_{M,N}(\mathbb{R})$, tel que $M \ll N$
- 3 **Objectif**: pouvoir reconstruire x_0 à partir de y, Φ

Hypothèses fondamentales pour pouvoir reconstruire exactement x_0

x_0 est s -sparse (i.e, possède au plus s coordonnées non nulles) avec $s \ll N$, $M \sim s \log(N/s)$, Φ vérifie RIP(s)

Problème à résoudre

- La condition RIP(s) est la suivante:

$$\forall x \in \mathbb{R}^N \text{ tq } \|x\|_0 = s, \quad \frac{1}{2} \|x\|_2 \leq \frac{\|\Phi x\|_2}{\sqrt{M}} \leq \frac{3}{2} \|x\|_2$$

- Minimisation l_0 pas faisable en pratique

Minimisation l_1

$$\begin{aligned} \text{Trouver } \tilde{x} = \underset{x \in \mathbb{R}^N}{\operatorname{argmin}} \quad & \|\Psi x\|_1 \\ \text{s.c. } & y = \Phi x \end{aligned}$$

Images satellites: des données bruitées

- Phénomènes naturels de bruits physiques des instruments de mesure
- Ajout d'un bruit gaussien dans la modélisation

Minimisation l_1 d'un signal bruité $z \sim N(0, \sigma_z^2)$

$$\text{Trouver } \tilde{x} = \underset{x \in \mathbb{R}^N}{\operatorname{argmin}} \|\Psi x\|_1$$

$$\text{s.c. } \|y - \Phi \Psi x\|_2^2 \leq M \sigma_z^2$$

- Des phénomènes de brouillage et des bruits de quantification pourraient également être pris en compte

Acquisition d'un signal en dimension 2

```
Data : Image  $X$ , Nombre de mesures  $M$   
for  $i = 1$  to  $N_{row}$  do  
    | Simuler  $\Phi_i$  telle que :  $\forall k, j \in [1, M] \times [1, N_{col}], \Phi_{j,k}^i \sim N(0, 1/M)$ ;  
    |  $Y_i = \Phi^i X_i$ ;  
end  
return  $Y$ 
```

Algorithm 1: Acquisition du signal

- 1 La matrice de mesures Φ :
On génère une matrice $\Phi_i \in \mathcal{M}_{M, N_{col}}(\mathbb{R})$ telle que
 $\forall k, j \in [1, M] \times [1, N_{col}], \Phi_{k,j} \sim N(0, 1/M)$
- 2 On construit chaque mesure Y_i par la transformation linéaire
 $\Phi_i x_0^i$

Algorithme de reconstruction d'un signal 2D

```
Data :  $Y, [\Phi^i], \mathcal{F}, P$   
 $n \leftarrow 0$   
 $X^{(n)} \leftarrow \mathcal{F}(Y, \Phi)$   
repeat  
   $n \leftarrow n + 1$   
  for  $i = 1$  to  $N_{row}$  do  
    if  $i = 1$  or  $i = N_{row}$  then  
       $x_P \leftarrow (X^{(n-1)})_i^T$   
    else  
       $x_P \leftarrow P((X^{(n-1)})_{i-1}, (X^{(n-1)})_{i+1})$   
    end if  
     $y_P \leftarrow \Phi^i x_P$   
     $e_Y \leftarrow Y_i^T - y_P$   
     $e_\theta \leftarrow \underset{e}{\operatorname{argmin}} \|e\|_{L_1} \quad \text{s.t.} \quad \Phi^i \Psi e = e_Y$   
     $e_X = \Psi e_\theta$   
     $(X^{(n)})_i^T \leftarrow (x_P + e_X)^T$   
  end  
until Convergence  
return  $X^{(n)}$ 
```


Algorithm 2: Reconstruction du signal (dimension 2)

Principe de l'algorithme de reconstruction 2D

- ➊ **Initialisation:** Les auteurs proposent d'initialiser de manière triviale en appliquant l'algorithme l_1 sur chaque ligne de l'image indépendamment des autres
- ➋ **Fonction de prédiction P :** plusieurs fonctions possibles (voir dans la partie computationnelle) basées sur une potentielle dépendance entre les lignes
- ➌ **Procédure l_1** sur les erreurs après application du filtre
- ➍ Extension possible aux signaux 3D en adaptant l'algorithme, les étapes sont transposées à des matrices et non plus des vecteurs colonnes

Quels paramètres et fonctions de prédiction?

Figure: Image satellite 300*300 pixels



Quels paramètres et fonctions de prédiction?

3 fonctions de prédictions (ou filtre) P :

$$\textcircled{1} \quad x_P = \frac{1}{2}(x_{i-1} + x_{i+1})$$

$\textcircled{2}$

$$x_{Pj} = \frac{1}{6}(x_{i-1,j-1} + x_{i-1,j} + x_{i-1,j+1} + x_{i+1,j-1} + x_{i+1,j} + x_{i+1,j+1})$$

$\textcircled{3}$


$$x_{Pj} = ax_{i-1,j-1} + bx_{i-1,j} + ax_{i-1,j+1} + ax_{i+1,j-1} + bx_{i+1,j} + ax_{i+1,j+1}$$

avec $a = \frac{2-\sqrt{2}}{4}$ et $b = \frac{\sqrt{2}-1}{2}$


On fait varier M le nombre de mesures entre 50 et 300 (pas de 50)

Résultats obtenus: cas $M=50$





Filtre 2



Filtre 1




Filtre 3




Résultats obtenus: cas $M=150$








Filtre 2



Filtre 1




Filtre 3




Résultats obtenus: cas $M=250$








Filtre 2



Filtre 1




Filtre 3



Conclusions et comparaisons avec les résultats des auteurs

- Une baisse exponentielle de la MSE et une convergence très rapide
- Meilleurs résultats avec le filtre 2 et 3 et M plus élevé
- Résultats en adéquation avec ceux des auteurs



Bibliographie

- M. Carlván, L. Blanc-Féraud, M. Antonini, C. Thiebaud & C. Latry, *A satellite imaging chain based on the Compressed Sensing technique*
- G. Coluccia, S.K. Kuiteing, A. Abrardo, M. Barni & E. Magli, *Progressive compressed sensing and reconstruction of multidimensional signals using hybrid transform/prediction sparsity model*